

МИНОБРНАУКИРОССИИ

Федеральное государственное бюджетное образовательное учреждение высшего образования

«МИРЭА— Российский технологический университет» РТУМИРЭА

Институт кибербезопасности и цифровых технологий направление 10.04.01 «Информационная безопасность»

Кафедра КБ-4«Интеллектуальные системы информационной безопасности»

Практическая работа №4

по дисциплине:

«Анализ защищенности систем искусственного интеллекта»

Выполнил:

Стельмах Н. Е.

Группа: ББМО-02-22

Проверил:

Спирин А. А.

Устанавливаем пакет ART

```
!pip install adversarial-robustness-toolbox
Executed at 2023.12.26.20.52.28 in 2s.478ms

Requirement already satisfied: adversarial-robustness-toolbox in c:\python\aszii\lib\site-packages (1.16.6)
Requirement already satisfied: scikit-learn<1.2.0,>=0.22.2 in c:\python\aszii\lib\site-packages (from adversarial-robustness-toolbox) (1.16.0)
Requirement already satisfied: six in c:\python\aszii\lib\site-packages (from adversarial-robustness-toolbox) (1.16.0)
Requirement already satisfied: tydm in c:\python\aszii\lib\site-packages (from adversarial-robustness-toolbox) (4.66.1)
Requirement already satisfied: setuptools in c:\python\aszii\lib\site-packages (from adversarial-robustness-toolbox) (65.5.1)
Requirement already satisfied: numpy>=1.18.0 in c:\python\aszii\lib\site-packages (from adversarial-robustness-toolbox) (1.26.1)
Requirement already satisfied: scipy>=1.4.1 in c:\python\aszii\lib\site-packages (from adversarial-robustness-toolbox) (1.14)
Requirement already satisfied: joblib==1.0.0 in c:\python\aszii\lib\site-packages (from scikit-learn<1.2.0, >=0.22.2->adversarial-robustness-toolbox)
Requirement already satisfied: threadpoolctl>=2.0.0 in c:\python\aszii\lib\site-packages (from scikit-learn<1.2.0, >=0.22.2->adversarial-robustness-toolbox)
Requirement already satisfied: colorama in c:\python\aszii\lib\site-packages (from tydm->adversarial-robustness-toolbox) (0.4.6)

WARNING: Error parsing requirements for torch: [Erron 2] No such file or directory: 'c:\python\aszii\\lib\site-packages\\torch-2.1.0.dist-info\\METADATA'

[notice] A new release of pip available: 22.3.1 -> 23.3.2
[notice] To update, run: python.exe =n pip install --upgrade pip
```

Импортим либы

```
∀from __future__ import absolute_import, division, print_function, unicode_literals
import os, sys
from os.path import abspath
module_path = os.path.abspath(os.path.join('..'))
if module_path not in sys.path:
    sys.path.append(module_path)
import warnings
warnings.filterwarnings('ignore')
import tensorflow as tf
tf.compat.v1.disable_eager_execution()
tf.get_logger().setLevel('ERROR')
import tensorflow.keras.backend as k
 from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense, Flatten, Conv2D, MaxPooling2D, Activation, Dropout
import numpy as np
import matplotlib.pyplot as plt
%matplotlib inline
from art.estimators.classification import KerasClassifier
 from art.attacks.poisoning import PoisoningAttackBackdoor,PoisoningAttackCleanLabelBackdoor
from art.attacks.poisoning.perturbations import add_pattern_bd
from art.utils import load_mnist, preprocess, to_categorical
 from art.defences.trainer import AdversarialTrainerMadryPGD
```

Rea

Грузим набор данных

```
# Набор данных MNIST
(x_raw, y_raw), (x_raw_test, y_raw_test), min_, max_ = load_mnist(raw=True)
# (Псевдо)случайная выборка:
n_train = np.shape(x_raw)[0]
num_selection = 10000
random_selection_indices = np.random.choice(n_train, num_selection)
x_raw = x_raw[random_selection_indices]
y_raw = y_raw[random_selection_indices]
```

Чистим данные

```
# Травим обучающую выборку

percent_poison = .33

x_train, y_train = preprocess(x_raw, y_raw)

x_train = np.expand_dims(x_train, axis=3)

x_test, y_test = preprocess(x_raw_test, y_raw_test)

x_test = np.expand_dims(x_test, axis=3)

# Мешаем данные

n_train = np.shape(y_train)[0]

shuffled_indices = np.arange(n_train)

np.random.shuffle(shuffled_indices)

x_train = x_train[shuffled_indices]

y_train = y_train[shuffled_indices]
```

Пишем функцию create_model() для создания последовательной модели из 9 слоев

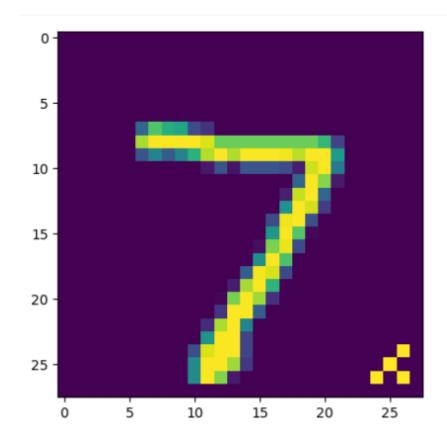
```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense, Flatten, Conv2D, MaxPooling2D, Dropout

☐ def create_model():
    model = Sequential() # Архитектура модели
    model.add(Conv2D(32, (3, 3), activation='relu', input_shape=(28, 28, 1))) # Первый светрочный слой
    model.add(Conv2D(64, (3, 3), activation='relu')) # Второй сверточный слой
    model.add(MaxPooling2D(pool_size=(2, 2))) # Слой пулинга
    model.add(Dropout(0.25)) # Дропаут слой
    model.add(Platten()) # Слой выравнивания
    model.add(Dense(128, activation='relu')) # Полносвязный слой
    model.add(Dense(10, activation='softmax')) # Второй полносвязный слой
    # Компиляция
    model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])

☐ return model # Возврат модели
```

Создаем атаку

```
backdoor = PoisoningAttackBackdoor(add_pattern_bd)
example_target = np.array([0, 0, 0, 0, 0, 0, 0, 0, 0, 1])
pdata, plabels = backdoor.poison(x_test, y=example_target)
plt.imshow(pdata[0].squeeze())
```



Определяем целевой класс атаки

```
targets = to_categorical([9], 10)[0]
Executed at 2023.12.26 20:52:38 in 28ms
```

Делаем модель

```
model = KerasClassifier(create_model())
proxy = AdversarialTrainerMadryPGD(KerasClassifier(create_model()), nb_epochs=10, eps=0.15, eps_step=0.001)
proxy.fit(x_train, y_train)
Executed at 2023.12.26 21:02:44 in 10m 5s 96ms

Precompute adv samples: 100%

1/1 [00:00<00:00, 111.19it/s]

Adversarial training epochs: 100%

10/10 [10:03<00:00, 60.44s/it]
```

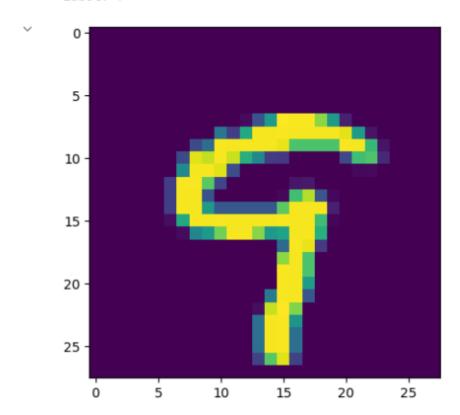
Выполняем атаку



Травим примеры данных

```
poisoned = pdata[np.all(plabels == targets, axis=1)]
poisoned_labels = plabels[np.all(plabels == targets, axis=1)]
print(len(poisoned))
idx = 0
plt.imshow(poisoned[idx].squeeze())
print(f"Label: {np.argmax(poisoned_labels[idx])}")
Executed at 2023.12.26 21:03:32 in 216ms
```

1030 Label: 9



Обучаем модель на отравленных данных

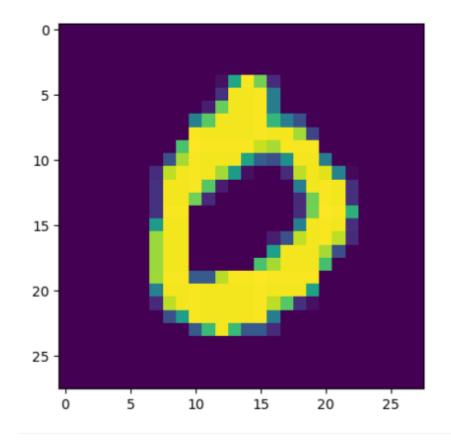
Тестируем чистую модель

```
clean_preds = np.argmax(model.predict(x_test), axis=1)
clean_correct = np.sum(clean_preds == np.argmax(y_test, axis=1))
clean_total = y_test.shape[0]
clean_acc = clean_correct / clean_total

print("\nЧистая точность тестового набора: %.2f%%" % (clean_acc * 100))

# как отравленная модель классифицирует чистую
c = 0 # Класс для показа
i = 0 # изображение класса для отображения
c_idx = np.where(np.argmax(y_test, 1) == c)[0][i] # индекс изображения в чистых массивах
plt.imshow(x_test[c_idx].squeeze())
plt.show()
clean_label = c
print("Прогноз: " + str(clean_preds[c_idx]))
Executed at 2023.12.26 21:05:00 in 2s 902ms
```

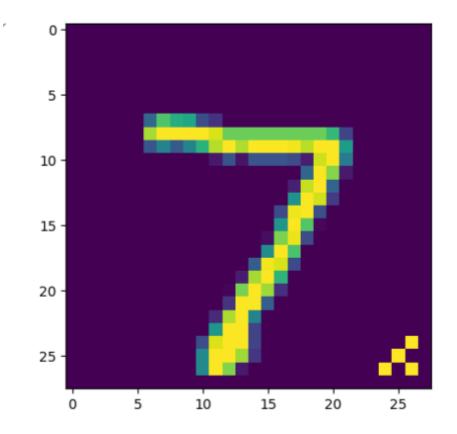
Чистая точность тестового набора: 98.11%



Прогноз: 0

Получаем результаты атаки на модель

```
not_target = np.logical_not(np.all(y_test == targets, axis=1))
1
   px_test, py_test = backdoor.poison(x_test[not_target], y_test[not_target])
2
3
   poison_preds = np.argmax(model.predict(px_test), axis=1)
   poison_correct = np.sum(poison_preds == np.argmax(y_test[not_target],
   axis=1))
5
   poison_total = poison_preds.shape[0]
   poison_acc = poison_correct / poison_total
7
8
   print("\nТочность тестера на яд: %.2f%%" % (poison_acc * 100))
0
   с = 0 # индекс для отображения
1
   plt.imshow(px_test[c].squeeze())
2
   plt.show()
   clean_label = c
   print("Прогноз: " + str(poison_preds[c]))
   Executed at 2023.12.26 21:05:03 in 2s 637ms
```



Прогноз: 9

Ретроспективно поясняем за код.